

# 國立虎尾科技大學資訊工程系

---

## 實務專題(二)製作報告

### 深度偽造語音偵測系統

指導教授：江季翰 教授

組員名單：41243128 姓名 徐聖硯

41243129 姓名 張帝淇

41243133 姓名 郭至峻

41243134 姓名 郭品佑

中華民國 115 年 06 月 09 日

## 摘要

隨著 AI 技術越發普及，合成音訊的演算法及工具也隨之增加與進步，也改變了虛擬駐守、語言學習等等應用，但也讓不法分子製造假消息的成本大幅降低，虛假的音訊、對話在社群越發常見，透過使用 Deepfake 合成政治人物的虛假音訊，並大量散布假消息進而影響選舉結果；亦或是假冒公司老闆等人物來進行網路釣魚，進而導致帳戶被劫持、資產與資料被盜取。

然而音訊偽造與自然語音日益難以區分，且研究顯示，人類對於身為音訊的判斷準確率僅約 73%，因此如何解決這些問題成為了莫大且急迫的需求。

為了解決這些問題，本專題開發一套系統配合手機 App，手機 App 提供使用者錄製以及上傳音訊檔案至伺服器，在伺服器端透過高通濾波做前處理以及梅爾頻率做特徵擷取，隨後利用深度學習的人工神經網路 ANN (Artificial neural network) 進行分類，並將分類結果回傳手機 APP。

模型訓練資料集來自” In The Wild”、” The Fake-or-Real( FoR)”、” DEEP-VOICE: Deepfake Voice Recognition”，這些資料集包含各種深度偽造演算法生成的真實與偽造音訊。實驗結果顯示，在攻擊者模擬電話以及發送語音訊息測試資料集中達到 93.65%的準確率。

關鍵詞：Deepfake、深度偽造音訊偵測、金融詐騙

# 目錄

|                     |    |
|---------------------|----|
| 摘要.....             | I  |
| 目錄.....             | II |
| 表目錄.....            | IV |
| 圖目錄.....            | V  |
| 第壹章 緒論.....         | 1  |
| 1.1 研究動機.....       | 1  |
| 1.2 研究目的.....       | 1  |
| 1.3 系統特色.....       | 1  |
| 1.4 可解決那些問題.....    | 1  |
| 第貳章 文獻回顧與探討.....    | 2  |
| Deepfake（深度偽造）..... | 2  |
| Deepfake 語音特徵.....  | 2  |
| 梅爾頻率倒譜係數.....       | 2  |
| 頻譜圖.....            | 2  |
| 基頻與韻律特徵.....        | 2  |
| 小波係數.....           | 3  |
| 語音前處理技術.....        | 3  |
| 高通濾波.....           | 3  |
| 訊號強化.....           | 3  |
| 池化降維.....           | 3  |
| 第參章 研究方法.....       | 4  |
| 3.1 研究步驟.....       | 4  |
| 3.2 系統架構圖說明.....    | 4  |
| 3.2.1 前端行動應用程式..... | 5  |
| 3.2.2 語音前處理模組.....  | 5  |

|       |                      |    |
|-------|----------------------|----|
| 3.2.3 | Deepfake 音訊檢測模組..... | 5  |
| 3.2.4 | 後端資料庫.....           | 6  |
| 甲、    | 資料庫表單.....           | 6  |
| 乙、    | 資料庫密碼加密.....         | 7  |
| 丁、    | ER Model.....        | 7  |
| 3.3   | 系統流程圖.....           | 8  |
| 3.4   | 開發環境.....            | 8  |
| 3.5   | 研究方法.....            | 8  |
| 1.    | 前處理.....             | 8  |
| 2.    | 深度學習模型架構.....        | 10 |
| 第肆章   | 實驗結果.....            | 12 |
|       | 專題實驗結果.....          | 12 |
| 4.1   | 資料集.....             | 12 |
| 4.2   | 實驗結果.....            | 14 |
| 4.3   | 解決問題.....            | 15 |
| 4.4   | 結論.....              | 15 |
| 4.5   | 未來展望.....            | 16 |
|       | 參考文獻.....            | 17 |
|       | 附錄.....              | 18 |

# 表目錄

|                                              |    |
|----------------------------------------------|----|
| 表 3.1 資料表結構.....                             | 6  |
| 表 3.2 User 表 .....                           | 6  |
| 表 3.3 Records 表.....                         | 6  |
| 表 4.1 所使用的資料集.....                           | 12 |
| 表 4.2 FoR 資料集中的四個版本.....                     | 13 |
| 表 4.3 FoR 資料集所提及的資料集 .....                   | 13 |
| <a href="#"><u>表 4.4 與其他模型比較結果</u></a> ..... | 13 |

# 圖目錄

|                                          |    |
|------------------------------------------|----|
| 圖 3.2.1 系統架構圖 .....                      | 5  |
| 圖 3.2 ER 模型 .....                        | 7  |
| 圖 3.3 流程圖 .....                          | 8  |
| 圖 4.1 使用 for-rerrec 內測試集的輸出結果 .....      | 14 |
| 圖 4.2 使用 for-rerrec 內測試集的輸出結果 .....      | 14 |
| 圖 4.3 偵測 Real 語音畫面 .....                 | 13 |
| 圖 4.4 偵測 Fake 語音畫面 .....                 | 13 |
| 圖 4.5 頻譜圖 (Real 在上 Fake 在下) 取自:[4] ..... | 15 |

# 第壹章 緒論

## 1.1 研究動機

伴隨著人工智慧（Artificial Intelligence）技術的快速進步，許多不法份子也開始使用生成式人工智慧（Generative Artificial Intelligence）合成語音來模仿受害者家人、朋友或銀行客服，並隨著逼真程度越來越高，令受害者難以快速分辨而因此受騙。

## 1.2 研究目的

本專題預計開發一套結合行動裝置之即時 Deepfake 語音檢測系統。透過改善語音前處理流程（高通濾波與梅爾頻率轉換），並佈署人工神經網路（ANN），維持高準確率的前提下，降低運算延遲，提供一般民眾防範語音詐騙之實用解決方案。

## 1.3 系統特色

- 操作簡單，使用者只需從手機選取音檔即可進行分析。
- 能協助使用者判斷可疑語音是否可能為詐騙。
- 分析完成後立即顯示是否為 Deepfake 的百分比。

## 1.4 可解決那些問題

- 一般民眾難以分辨 Deepfake 語音。
- 傳統防詐騙方法不足。
- 使用者收到可疑語音時沒有工具可驗證。
- 減少詐騙成功率。

## 第貳章 文獻回顧與探討

此章節會介紹各個技術或是專有名詞，讓讀者能快速理解本專題後續的內容。

### Deepfake（深度偽造）

深度偽造是由深度學習以及偽造兩詞組合而來，是指使用人工智慧或基於人工智慧的工具或音訊、視訊編輯軟體所編輯或產生的影像或音訊。這項技術在語音的部分又分為文字轉語音、語音轉換、情感偽造、場景偽造、部分偽造[2]。

文字轉語音：把文本輸入到模組內就可以生成一段 Deepfake 的文字轉語音。

語音轉換：假設有 A、B 兩人，先對 A 說的話做去背景聲，接著把 A 說的這段話和 B 的聲音參數輸入至 RVC model（Retrieval-Based Voice Conversion），就會生成一段用 B 的聲音說 A 的話，最後再把原來的背景聲加上，就完成語音轉換了。

情感偽造：即改變說話的情緒語氣。

場景偽造：透過偽造或修改音訊來模擬特定的環境背景。

部分偽造：其中只有音訊片段的某些部分被篡改，而其他部分則保持原樣。

### Deepfake 語音特徵

語音特徵是指從原始音訊波形中萃取出數值表示，用於描述聲音在時間與頻率上的變化規律。常見的語音特徵包含以下幾類：

#### 梅爾頻率倒譜係數（Mel-Frequency Cepstral Coefficients，MFCC）：

MFCC 模擬人耳對頻率的非線性感知方式，將語音訊號轉換為一組能反映聲道共振特性的係數[8]。它是目前語音辨識與偵測中最廣泛使用的特徵之一，對說話者的音色和發音習慣有高度敏感性。Deepfake 語音由模型合成，聲道模擬通常不夠完整，因此在 MFCC 分布上往往與真人語音存在統計差異，例如高頻係數的變化幅度較為平滑、缺乏自然人聲在換氣或停頓前後的細微抖動。

頻譜圖（Spectrogram）：頻譜圖以時間為橫軸、頻率為縱軸，顏色深淺表示能量強弱，可直觀呈現語音在各頻段隨時間的變化。真實語音的頻譜圖通常有清晰的共振峰（Formant）軌跡，以及聲帶振動所形成的諧波結構

（Harmonics）；Deepfake 語音受限於合成模型的架構，有時會在特定頻段出現不自然的能量分布，或是諧波結構過於規律、缺少真人語音中常見的細微擾動[4]。

基頻與韻律特徵（Pitch / Prosody）：基頻（F0）即俗稱的音高，反映聲帶每秒振動的次數；韻律則涵蓋語調起伏、語速快慢、停頓節奏等特性。真人說話時，基頻會隨語境情緒自然起伏，且在音節連接處存在微小的音高過渡；Deepfake 語音的基頻變化往往過於平滑或在句末出現不自然的音調下降，難以



精確複製真人情感語調[4]。Warren 等人的研究即針對這類韻律特徵進行分析，證實 Deepfake 語音在音高輪廓與停頓模式上存在可偵測的差異。

**小波係數 (Wavelet Coefficients)**：不同於傅立葉轉換只能分析全域頻率分布，小波轉換能同時捕捉語音訊號在時間與頻率上的局部變化，對瞬間發音細節（如爆破音、摩擦音）的描述更為精確。Reham Mohamed Abdulhamied 等人的論文[3]即採用 4 層小波分解 (4-Level Wavelet Decomposition) 作為 ANN 模型的輸入特徵，同時在 ResNet50 模型中搭配頻譜圖，透過兩種特徵互補偵測 Deepfake 語音，實驗結果顯示此方法在偵測精準度上優於單一特徵的方案。

### 語音前處理技術

為了讓深度學習模型能夠有效學習語音中的 Deepfake 特徵，原始音訊在送入模型之前通常需要經過一系列前處理步驟，以提升訊號品質並萃取出具有代表性的特徵。本系統採用的語音前處理流程主要包含三個核心技術：高通濾波、訊號強化，以及池化降維，以下分別說明其原理與在本系統中的用途。

**高通濾波 (High-pass Filter)**：濾波器是一種對訊號特定頻率成分進行保留或衰減的處理工具。高通濾波器的作用是允許高於某一截止頻率的訊號通過，同時衰減低頻成分。在語音訊號中，低頻雜訊主要來源包括環境背景音（如冷氣聲、風聲）及麥克風震動等，這些噪音頻率通常低於 80 Hz，並不包含有意義的語音資訊。套用高通濾波後，可有效去除這類干擾，使後續特徵提取更聚焦於語音本身的頻率區間（一般人聲基頻約在 80–300 Hz，而聲道諧波可延伸至數千 Hz），進而提升模型辨識的穩定性。

**訊號強化 (Signal Enhancement)**：完成濾波後，語音訊號的振幅可能因錄音環境或設備差異而有所不同，直接輸入模型容易造成學習不穩定。訊號強化的目的是對語音訊號進行振幅正規化 (Amplitude Normalization) 或預加重 (Pre-emphasis) 處理。預加重是一種常見的強化手法，透過對訊號微分（即對相鄰取樣點做差值），放大高頻成分、補償頻譜傾斜，使頻譜在各頻段的能量分布更為均衡[10]。振幅正規化則確保不同來源的音檔在輸入模型時具有一致的能量尺度，避免模型因音量差異而產生偏誤，有助於提升跨資料集的泛化能力。

**池化降維 (Pooling)**：池化是深度學習中常見的降維操作，常見形式有最大池化 (Max Pooling) 與平均池化 (Average Pooling) 兩種。最大池化從一個局部區域中取最大值，保留最顯著的特徵；平均池化則取區域平均值，呈現整體趨勢。在語音處理的脈絡中，特徵提取（如 MFCC 或頻譜圖）後所得到的特徵矩陣維度往往很高，直接輸入模型會大幅增加計算量並容易過擬合

(Overfitting)。池化操作透過壓縮特徵圖的空間尺寸，在保留關鍵語音特徵的同時，精簡模型需處理的資料量，使模型訓練更有效率，也提升對輸入訊號細微位移的容忍度（平移不變性）。本系統在語音前處理模組的最後階段套用池化，輸出精簡後的特徵表示，再送入 Deepfake 音訊檢測模組進行推論。

## 第參章 研究方法

此章節會介紹本專題的研究步驟、系統架構圖說明、前端行動應用程式、前處理模組、Deepfake 音訊檢測模組、後端資料庫、系統流程圖、開發環境、研究方法的介紹，並且提供了一些圖表進行輔助說明。

### 3.1 研究步驟

- 前置作業
  1. 收集相關技術資訊
  2. 收集 Deepfake 與真實語音資料集
  3. 整理資料格式
  4. 建立資料庫結構（使用者、音檔、分析結果）
- 前端 APP 開發
  1. 使用 Android Studio 開發 APP
  2. 實作「選取音檔」功能
  3. 實作「上傳音檔至後端」功能
  4. 美化使用者介面
- 模型訓練
  1. 建立 Deepfake 偵測模型
  2. 訓練語音 Deepfake 偵測模型
  3. 產生推論結果（真實語音／Deepfake 機率）
  4. 驗證 Deepfake 偵測模型準確性
- 後端伺服器建置
  1. 建立 API 接收音檔並呼叫模型分析
  2. 回傳 Deepfake 判斷結果給 App
  3. 管理音檔存取與模型版本
- 資料庫建置
  1. 建立上傳紀錄資料集
  2. 儲存分析結果與使用者查詢紀錄
  3. 提供 App 查詢歷史記錄分析功能

### 3.2 系統架構圖說明

本專題所設計的「深度偽造音訊偵測系統」，其整體系統架構與資料流向如圖 3.2.1 所示。系統主要由前端輸入音訊、雲端後端偵測系統（包含語音前處理模組與 Deepfake 音訊檢測模組）、ANN，以及 MariaDB 資料庫所組成。以下針對各大核心模組與資料流向進行詳細說明：

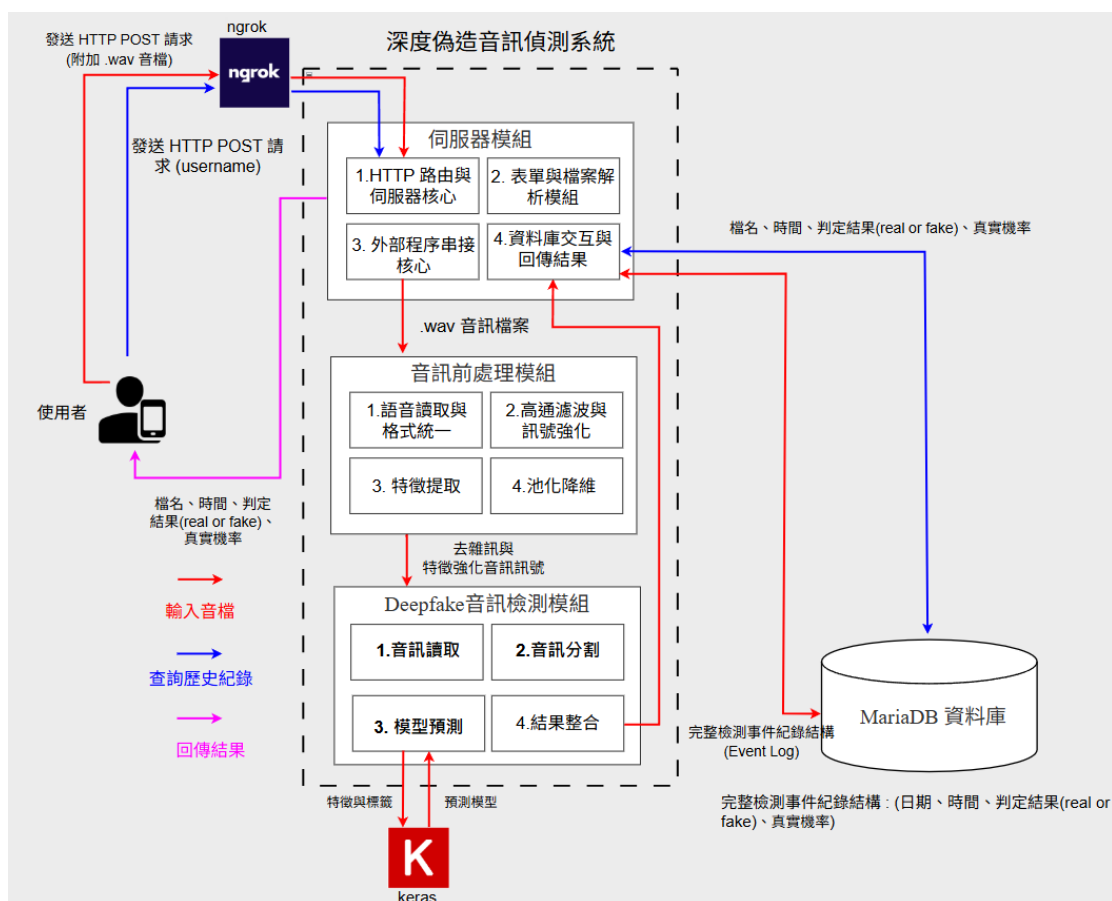


圖 3.2.1 系統架構圖

### 3.2.1 前端行動應用程式

使用者透過智慧型手機上的 App 介面進行操作。App 負責提供音檔選取功能，並將音訊統一封裝為 .wav 格式音檔，透過 API 即時上傳至雲端後端偵測系統。同時，App 也負責接收並顯示判定結果。

### 3.2.2 語音前處理模組

後端伺服器接收到 .wav 音檔後，首先進入語音前處理模組，該模組包含以下四個主要步驟，用以優化音訊品質並提取關鍵特徵：

甲、**語音讀取與格式統一**：讀取上傳的音訊檔案，確保其採樣率（Sampling Rate）與聲道等特徵完全一致。

乙、**高通濾波與信號強化**：利用高通濾波器（High-pass Filter）濾除環境中的低頻噪音，並對語音信號進行強化。

丙、**特徵提取**：將強化後的語音訊號轉換為適合深度學習模型輸入的聲學特徵（如 MFCC 或語音頻譜圖）。

丁、**池化降維**：透過池化（Pooling）技術精簡特徵維度、擷取關鍵特徵，最後輸出「去雜訊與特徵強化之音訊訊號」至下一階段。

### 3.2.3 Deepfake 音訊檢測模組

此模組為本系統的核心推論引擎，負責整合訓練好的 ANN 模型並進行即時辨識，運作流程如下：

甲、**音訊讀取**：接收來自前處理模組輸出之強化特徵訊號。

乙、音訊分割：將長段語音依特定時間長度進行切片分割，以便模型能針對局部語音特徵進行精細分析。

丙、模型預測：此步驟使用外部的 Keras 深度學習 API 來進行 ANN 模型訓練，將特徵作為輸入，並使用 Dense 全連階層搭配 Rectified Linear Unit 線性整流函數來訓練模型，而後將輸入的已分割音檔放入已訓練好的模型進行判斷。

丁、結果整合與輸出：整合各音訊切片的預測機率，計算出最終的判定結果。一方面將結果透過伺服器模組即時回傳給前端 App 顯示，另一方面將「完整檢測事件紀錄結構（Event Log）」傳送至後端資料庫。

### 3.2.4 後端資料庫

系統後端連接 MariaDB 資料庫，當 Deepfake 音訊檢測模組完成「結果整合與輸出」後，會將包含使用者資訊、音檔特徵、偵測時間及判定結果的完整檢測事件紀錄結構（Event Log）寫入資料庫中。

甲、資料庫表單：在資料庫中，本系統主要設計兩張核心實體資料表（Users、Records）與其關聯，分別為 Users 跟 Records，分別存放用戶以及音檔紀錄。

表 3.1 資料表結構

| Table   |
|---------|
| Users   |
| Records |

表 3.2 USER 表

| Field    | Type         | NULL | Key | Default | Extra          |
|----------|--------------|------|-----|---------|----------------|
| Id       | Int(11)      | No   | PRI | NULL    | Auto_increment |
| Username | Varchar(50)  | No   | UNI | NULL    |                |
| Gmail    | Varchar(255) | No   | UNI | NULL    |                |

表 3.3 RECORDS 表

| Field              | Type         | NULL | Key | Default           | Extra          |
|--------------------|--------------|------|-----|-------------------|----------------|
| Id                 | Int(11)      | No   | PRI | NULL              | Auto_increment |
| Username           | Varchar(50)  | No   | UNI | NULL              |                |
| Filename           | Varchar(50)  | No   |     | NULL              |                |
| Result             | Text         | No   |     | NULL              |                |
| Created_at         | Timestamp    | No   |     | Current_timestamp |                |
| Original_file name | Varchar(255) | No   |     | NULL              |                |

乙、資料庫加密：為了保證用戶的安全性，使用單向雜湊函數（One-way Hash Function）進行雜湊處理。

丙、**One-way Hash Function**：導入了專為密碼防禦設計的 Bcrypt 單向雜湊函數，並將工作因子（Salt Rounds）設定為 10。Bcrypt 內建的自動加鹽（Salt）機制能徹底杜絕彩虹表對照攻擊；其慢速雜湊的特性也能大幅拉高駭客線下暴力破解的算力成本，保證即使資料庫不幸外洩，使用者的明文密碼也絕對無法被還原。

丁、**ER Model**：




圖 3.2 ER Model

### 3.3 系統流程圖




圖 3.3 流程圖

### 3.4 開發環境

系統環境分為系統開發環境與使用者環境兩項。首先開發環境以 Windows11 個人電腦以及 Android 16 個人手機，工作時我們會以 Git 協助版本控制。開發語言則有 Node、Python、Kotlin、Java 與 SQL。而使用者環境為個人手機。

### 3.5 研究方法

#### 1. 前處理

甲、將音訊的取樣率進行標準化與分段，將所有輸入的音檔做統一重新取樣，並且將每段音訊檔案切分為一秒一個得不重複音訊。

乙、將切分完成的音訊檔案進行高通濾波，並運用高通濾波將頻率為100Hz以下的聲音給去除，藉此來去除音訊內的環境噪音。

$$|H(f)| = \frac{1}{\sqrt{1 + \left(\frac{f}{f_c}\right)^{2N}}}, N = 5, f_c = 100 \text{ Hz} \quad (4-1)$$

f : 輸入訊號頻率

f<sub>c</sub> : 截止頻率

N : 濾波器階數

丙、將處除完的音訊檔案進行預強調，為了補償音訊中高頻音量隨頻率衰減的特性，並凸顯高頻的部分。

$$\hat{y}[n] = x[n] - \alpha \cdot x[n-1] \quad (4-2)$$

x[n] : 第 n 個取樣點的原始訊號值

$\hat{y}[n]$  : 預強調後的輸出值

$\alpha$  : 預強調係數

丁、將預強調完的音訊進行梅爾頻率轉換，藉此將物理上的聲學頻率轉為與人類聽覺相似的頻率尺度。

$$m(f) = 2595 \cdot \log_{10} \left( 1 + \frac{f}{700} \right) \quad (4-3)$$

f : 物理頻率 (Hz)

m(f) : 對應的梅爾尺度頻率

戊、計算Delta，單一Frame的梅爾頻譜僅能表示靜態特徵。為了捕捉音訊特徵隨時間動態變化，因此我們計算了Delta與Delta-Delta來捕捉聲音的動態變化。

$$\Delta c[t] = \frac{\sum_{n=1}^N n \cdot (c[t+n] - c[t-n])}{2 \cdot \sum_{n=1}^N n^2} \quad (4-4)$$

$c[t]$ ：第  $t$  幀的特徵係數

$\Delta c[t]$ ：一階差分（捕捉特徵隨時間的變化速率）

$N$ ：前後各取的幀數

己、並將特徵正規化，針對整張特徵圖進行倒頻譜均值與變異數正規化消除不同音訊間的音量或通道失真差異，使特徵分佈更加穩定。

$$\hat{x} = \frac{(x - \mu)}{(\sigma + \varepsilon)} \quad (4-5)$$

$x$ ：原始特徵值

$\mu$ ：整張特徵矩陣的均值

$\sigma$ ：標準差

$\varepsilon$ ：極小常數（防止除以零）

$\hat{x}$ ：正規化後的特徵值

最後進行均值池化降維，為避免特徵維度過高導致後續神經網路發生過擬合，在時間軸上採用大小為 4 的均值池化進行降維在保留關鍵語音結構的同時，有效縮減特徵矩陣大小。最後將此二維矩陣壓平（Flatten）為一維特徵向量，作為神經網路的輸入。

$$pool[k] = \frac{1}{P} \cdot \sum_{i=kP}^{(k+1)P-1} f[i] \quad (4-6)$$

$f[i]$ ：幀的特徵向量

$P$ ：池化視窗大小

$k$ ：池化後的幀索引

## 2. 深度學習模型架構

甲、人工神經網路(ANN)由六層所組成：

輸入層（1024個節點）、四個隱藏層（512個節點、256個節點、128個節點、64個節點）、輸出層（1個節點），目標在於準確的學習並擷取特徵。



乙、激勵函數：

隱藏層皆使用ReLU (Rectified Linear Unit) 線性整流函數，以此來解決深度網路學習時梯度消失的問題，並加速模型收斂。

$$f(z) = \max(0, z) \quad (4-7)$$

$z$  : 上層神經元輸出的線性組合

$f(z)$  :  $z$ 如果大於零則輸出 $z$ ；反之則是零。

丙、輸出預測：

網路的最後一層使用Sigmoid函數，將連續的實數輸出壓縮至0到1之間，代表該音頻為真實音訊的機率。

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (4-8)$$

$\hat{y}$  : 模型預測出的機率值

$e$  : 自然常數

丁、損失函數

因為實驗屬於二分類任務，故在訓練過程使用Binary Crossentropy Loss 作為衡量模型預測誤差的損失函數。

$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (4-9)$$

$L$  : 整體的Loss

$M$  : 每次訓練中的Batch的樣本總數

$y_i$  : 第 $i$ 個樣本的真實標籤

$\hat{y}_i$  : 模型對第 $i$ 個樣本的預測機率

## 第肆章 實驗結果

此章節會介紹本專題的實驗結果，並且和其他論文的結果進行比較，可以看出利用高通濾替換小波去噪會提高模型的準確率。

### 專題實驗結果

開發一套可偵測 Deepfake 語音的系統，使用者可透過 APP 上傳音檔，在系統內可查詢過去的偵測紀錄，包含檔名、時間、日期和偵測的結果（real or fake 和 真實機率％），並且可直接使用手機 App 的錄音功能，對聲音進行錄製，達到 Deepfake 語音偵測的目的。

#### 4.1 資料集

1. 專題使用三個資料集，分別是” In The Wild (audio Deepfake)”、“The Fake-or-Real( FoR資料集)Dataset ( Deepfake audio)”、“DEEP-VOICE: Deepfake Voice Recongnition”，以上三個資料集皆是來自Kaggle平台。

表 4.1 所使用的資料集

| 名稱   | In The Wild              | The Fake-or-Real ( FoR )                                                     | DEEP-VOICE : Deepfake Voice Recognition |
|------|--------------------------|------------------------------------------------------------------------------|-----------------------------------------|
| 資料量  | 19963個真實音訊<br>11816個偽造音訊 | 169754個音訊檔案，包含真實以及偽造音訊。                                                      | 8個真實音訊<br>56個偽造音訊                       |
| 資料來源 | 社交網路與串流平台等公開管道           | 彙整了來自最新TTS solutions的數據，以及 LJSpeech Dataset 、VoxForge Dataset、Arctic Dataset | 八位知名人物的演講與訪談音訊                          |
| 特點   | 58位名人與政治人物的真實以及偽造音訊      | 資料集共有四個版本，for-original、for-norm、for-2sec、for-rerec                           | 此資料集的偽造音訊產生方法為RVC技術，並將八位人物的音訊進行交叉轉換     |

2. 本專題主要聚焦於The Fake-or-Real中的for-rerec版本做為參考指標，其各版本說明如表4.2：

表 4.2 FoR 資料集中的四個版本

| 版本名稱         | 版本說明                                                              |
|--------------|-------------------------------------------------------------------|
| for-original | 此版本為來源的音訊檔案，並未作任何修改                                               |
| for-norm     | 此版本包含與for-original版本相同的音訊檔案，差別於此版本將性別進行平均，並把取樣率、音量、聲道數進行標準化       |
| for-2sec     | 此版本基於for-norm版本，差別於此版本將每段音訊檔案的長度截斷為2秒為一個音訊檔案                      |
| for-rerec    | 此版本基於for-2sec版本，差別於此版本的音訊為for-2sec的再錄製版本，用於模擬攻擊者透過電話或是語音訊息發送音訊的場景 |

3. 資料集所提及之資料集如表4.3

表 4.3 FoR 資料集所提及的資料集

| 名稱   | Arctic Datasets               | LJSpeech Datasets                                             | VoxForge Datasets                             |
|------|-------------------------------|---------------------------------------------------------------|-----------------------------------------------|
| 資料量  | 1150個音訊檔案                     | 13100個音訊檔案                                                    | 為持續接收的開源資料庫，因此資料量會持續變動                        |
| 資料來源 | 為多個不同口音的專業配音員錄製而生             | 由一位女性朗讀者兩讀7本書籍                                                | 為網路上的自願者上傳之音訊檔案                               |
| 特點   | 專為TTS研究以及Voice Cloning設計的資料集。 | 為 Single Speaker TTS最常被使用的開源資料集，每段音訊檔案在1至十秒之間，只要依據句子的自然停頓進行切分 | 因為由網路上的自願者自行錄製與提交，每個人的麥克風品質、錄音環境、環境音、口音與語速都不同 |

## 4.2 實驗結果

本實驗採用結合高通濾波前處理與梅爾頻率倒譜係數(MFCC)特徵的 ANN 模型，於 FoR 資料集 (Fake-or-Real Dataset) 中的 for-rerec 子集進行測試。由混淆矩陣結果可知，模型正確辨識 Fake 樣本 1,081 筆、誤判為 Real 者 62 筆；正確辨識 Real 樣本 1,008 筆、誤判為 Fake 者 93 筆，整體平均準確率 (Accuracy) 達 **93.65%**。其中，模型對 Fake 樣本的召回率 (Recall) 約為 94.6%，顯示本系統在偵測偽造語音方面具有較高的靈敏度，漏判率相對偏低，符合詐騙偵測情境中對偽陽性控制的基本要求。

|           | 預測為 Fake | 預測為 Real |
|-----------|----------|----------|
| 真實為 Fake: | 1081     | 62       |
| 真實為 Real: | 93       | 1008     |

圖 4.1 使用 for-rerec 內測試集的輸出結果

|      | precision | recall | f1-score | support |
|------|-----------|--------|----------|---------|
| Fake | 0.92      | 0.95   | 0.93     | 1143    |
| Real | 0.94      | 0.92   | 0.93     | 1101    |

圖 4.2 使用 for-rerec 內測試集的輸出結果



圖 4.3 偵測 Real 語音畫面



圖 4.4 偵測 Fake 語音畫面

表4.4 與其他模型比較結果

|           | Our Model | ANN with Wavelet[3] | Prosody Deepfake Detector[4] |
|-----------|-----------|---------------------|------------------------------|
| Accuracy  | 93.65%    | 79.69%              | 93%                          |
| Precision | 0.93      | 0.82                | 0.61                         |
| Recall    | 0.935     | 0.938               | 0.66                         |
| F1 Score  | 0.93      | 0.87                | 0.63                         |

#### 4.3 解決問題

本系統所針對的核心問題，是一般民眾在日常通訊情境中缺乏快速、可靠的工具來識別 Deepfake 語音詐騙。現有的語音鑑識方案多數停留在學術或企業端，需要專業人員操作，對於沒有相關背景的使用者而言門檻過高。本系統透過行動應用程式（Android App）提供以下三項具體的問題解決方案：第一，即時偵測與結果呈現。使用者可透過 App 上傳音訊檔案或直接錄音，系統將音訊送入後端偵測模型進行推論，並將結果（真實／偽造判定及對應的真實機率百分比）即時回傳至 App 介面，讓使用者無需具備任何技術背景即可完成鑑識。第二，歷史紀錄查詢。App 內建偵測紀錄功能，完整保存每次偵測的檔名、日期、時間與結果，方便使用者事後複查或作為舉報依據。第三，降低技術門檻以提升詐騙防護覆蓋率。Deepfake 語音詐騙的受害族群往往是對新興技術認識不足的一般大眾；本系統以直覺化的介面設計為優先，將複雜的深度學習推論流程完全封裝在後端，使防護能力得以延伸至更廣泛的使用者群體。在偵測原理上，本系統利用頻譜圖（Spectrogram）作為核心視覺化特徵，如圖 4.3 所示，真實語音（Real）與 Deepfake 語音（Fake）在頻譜圖上存在可觀察的差異：Deepfake 語音的谐波結構較為規律平滑，缺少真人語音在語調起伏、音高轉換及停頓前後所呈現的細微擾動，模型即藉由學習這類頻譜層級的差異進行判別。




圖 4.5 頻譜圖（REAL 在上 FAKE 在下）取自:[4]

（1）起伏變化（2）停頓差異（3）、（4）為起伏變化、停頓差異與音高變異的綜合特徵組合

#### 4.4 結論

隨著深度偽造技術的進步，如何去偵測深度偽造的技術已然成為重中之重的研究。本系統使用結合高通濾波與梅爾頻率的人工神經網路做音訊識別，在

Fake-or-Real 資料集的 for-rerec 版本中達到了平均93.65%的準確率。

#### 4.5 未來展望

本系統在開發與測試過程中面臨數項技術困境，並已識別出對應的改善方向，以下分別就音訊擷取限制、模型泛化能力及系統延伸性三個面向加以說明。

**一、通話中音訊擷取的平台限制。**現行 Android 系統基於隱私保護政策，自 Android 10 起對一般應用程式嚴格限制通話中的麥克風存取權限：當裝置處於通話狀態時，系統會將音訊輸出路徑切換至通話專用的音訊焦點（Audio Focus），使第三方 App 無法同步錄製通話音訊。此限制導致本系統無法在接聽電話的同時即時對語音進行偵測，必須仰賴使用者事後錄音再上傳，降低了系統在即時詐騙情境中的可用性。目前可行的替代方案包括：（1）使用第二台裝置對擴音播出的通話音訊進行環境錄音；（2）使用原廠韌體中內建通話錄音功能的裝置並匯出錄音檔後送入偵測系統。然而上述方案均依賴額外的硬體條件，並不具備通用性。從改善方向來看，未來可考慮結合 VoIP 通訊協定（如 SIP/WebRTC）的應用情境，透過雲端電話接收通話封包並在伺服器端直接分析音訊串流，從根本繞過 Android 平台的麥克風限制。

**二、模型泛化能力的不足。**本系統現行模型主要以特定資料集（如 ASVspoof、FakeAVCeleb 等）訓練，對訓練資料中涵蓋的合成方式偵測效果較佳，但面對新興的 Deepfake 生成技術（如近年出現的零樣本語音克隆模型），模型的泛化能力可能下降。此外，訓練資料以英語語音為主，對中文或台語等語音的適應性尚待驗證。改善方向包括：定期以新型 Deepfake 語音樣本增量訓練模型（Continual Learning）、引入對抗訓練（Adversarial Training）機制以提升模型對未知合成方式的 Robustness，以及建立多語言訓練資料集以擴展偵測覆蓋範圍。

**三、系統延伸性與跨平台支援。**目前本系統僅支援 Android 平台，iOS 使用者無法使用本應用程式。由於 iOS 對應用程式背景執行及音訊 API 的限制方式與 Android 有所不同，移植難度較高。未來若要提升覆蓋率，可優先開發基於 Flutter 或 React Native 的跨平台版本，或改以 Web App 形式部署，使使用者無論使用何種裝置均可透過瀏覽器存取偵測功能。

## 參考文獻

- [1] 高信雄, 顏志平, and 嚴泓元, “基於 AI 語音特徵分析的智慧型手機深偽詐騙偵測研究,” *管理資訊計算*, vol. 13, pp. 20–29, 2020
- [2] B. Zhang, H. Cui, V. Nguyen, and M. Whitty, "Audio Deepfake Detection: What Has Been Achieved and What Lies Ahead," *Sensors*, vol. 25, no. 7, p. 1989, 2025.
- [3] R. M. Abdulhamied, S. Naiem, M. M. Nasr, and F. A. Moussa, "Deepfake Audio Detection Using Feature-Based and Deep Learning Approaches: ANN vs ResNet50," *International Journal of Advanced Computer Science and Applications (IJACSA)*, vol. 16, no. 6, 2025.
- [4] K. Warren, D. Olszewski, S. Layton, K. Butler, C. Gates, P. Traynor “Pitch Imperfect: Detecting Audio Deepfakes Through Acoustic Prosodic Analysis” ,2025
- [5] M. Abdeldayem, “The Fake-or-Real (FoR) Dataset (deepfake audio).” *Kaggle.com*, 2025. <https://www.kaggle.com/datasets/mohammedabdeldayem/the-fake-or-real-dataset/data>[Accessed January. 29, 2026]
- [6] R. Wang *et al.*, “DeepSonar: Towards Effective and Robust Detection of AI-Synthesized Fake Voices,” *MM '20: Proceedings of the 28th ACM International Conference on Multimedia* Pages 1207 – 1216(2020)
- [7] “聲學基礎知識：聲音的特徵與表現,” *Kknews.cc*, 2019. <https://kknews.cc/zh-tw/news/mj5xo99.html> [Accessed Dec. 10, 2025].
- [8] Z. Kh. Abdul and A. K. Al-Talabani, “Mel Frequency Cepstral Coefficient and its Applications: A Review,” *IEEE Access*, vol. 10, pp. 122136–122158, 2022,
- [9] Luís Vilça, Y. Yu, and P. Viana, “A Survey of Recent Advances and Challenges in Deep Audio-Visual Correlation Learning,” *ACM Computing Surveys*, vol. 57, no. 12, pp. 1–46, May 2025,
- [10] Harsh Ahlawat, N. Aggarwal, and D. Gupta, “Automatic Speech Recognition: A survey of deep learning techniques and approaches, ”*International Journal of Cognitive Computing in Engineering*, vol. 6, Pages 201-237 ( 2025)
- [11] "Deepfake. " *Wikipedia . Wikimedia Foundation*,17 May 2019 <https://en.wikipedia.org/wiki/Deepfake> [Accessed June. 08 2026]
- [12] "Mel-Frequency Cepstrum." *Wikipedia*, 21 Dec 2019 [https://en.wikipedia.org/wiki/Mel-frequency\\_cepstrum](https://en.wikipedia.org/wiki/Mel-frequency_cepstrum) [Accessed June. 08 2026]
- [13] "Spectrogram." *Wikipedia Contributors*, 17 Oct 2019 <https://en.wikipedia.org/wiki/Spectrogram> [Accessed June. 08 2026]
- [14] "High-pass filter." *Wikipedia Contivutors*, 22 Nov 2019 [https://en.wikipedia.org/wiki/High-pass\\_filter](https://en.wikipedia.org/wiki/High-pass_filter) [Accessed June. 08 2026]

# 附錄

組員工作分配表

|               | 徐聖硯 | 張帝淇 | 郭至峻 | 郭品佑 |
|---------------|-----|-----|-----|-----|
| 文獻探討          | ✓   | ✓   | ✓   | ✓   |
| 資料收集          | ✓   | ✓   | ✓   | ✓   |
| Malia DB資料庫建立 | ✓   |     |     | ✓   |
| APP開發         |     | ✓   | ✓   |     |
| 辨識模型開發        | ✓   | ✓   |     |     |
| 伺服器架設與測試      | ✓   |     | ✓   | ✓   |
| 資料彙整          |     |     |     | ✓   |
| APP前端美化       |     | ✓   |     |     |
| 系統整合          |     | ✓   |     |     |
| 文件撰寫          | ✓   | ✓   | ✓   | ✓   |




圖 甘特圖